



## **Laboratorio No. 2**

Carlos Edgardo López Barrera 21666

Brian Anthony Carrillo Monzon - 21108

Guatemala, 05 de agosto del 2024

## **Regresión para Predecir Ganancias (Worldwide Gross)**

### **Subconjunto de variables a utilizar:**

- runtime\_minutes
- movie\_averageRating
- movie\_numerOfVotes
- approval\_Index
- Production budget \$
- Domestic gross \$

### **1. Describa el objetivo de la red y por qué considera que la implementación de una red neuronal puede obtener el resultado deseado.**

El objetivo de la red neuronal es predecir el valor de “Worldwide gross \$” de una película basada en una serie de características relacionadas con la película, las cuales se seleccionaron como subconjunto de variables a utilizar. Estas características incluyen el tiempo de duración, la calificación promedio de la película, el número de votos, el índice de aprobación, el presupuesto de producción y las ganancias domésticas.

La implementación de una red neuronal puede obtener el resultado deseado de predecir las ganancias totales de una película debido a:

- Las redes neuronales son efectivas en la captura de relaciones complejas y no lineales entre variables. Por ejemplo en nuestro caso del dataset de películas, las ganancias totales pueden estar influenciadas por múltiples factores de manera no lineal.
- Una red neuronal puede generalizar bien a nuevos datos, por lo que nuestra red puede hacer predicciones precisas para películas que no fueron incluidas en el conjunto de entrenamiento.
- Las características seleccionadas como el presupuesto de producción, las calificaciones y las ganancias domésticas pueden interactuar de maneras complejas para influir en las ganancias totales.
- Las redes neuronales pueden ayudar a reducir el sesgo inherente en los datos al aprender representaciones abstractas de las características.

## 2. Describa la composición y los resultados obtenidos por la red neuronal.

### Red 1: Modelo Sin Batch Normalization (Unbatched Model)

#### Composición:

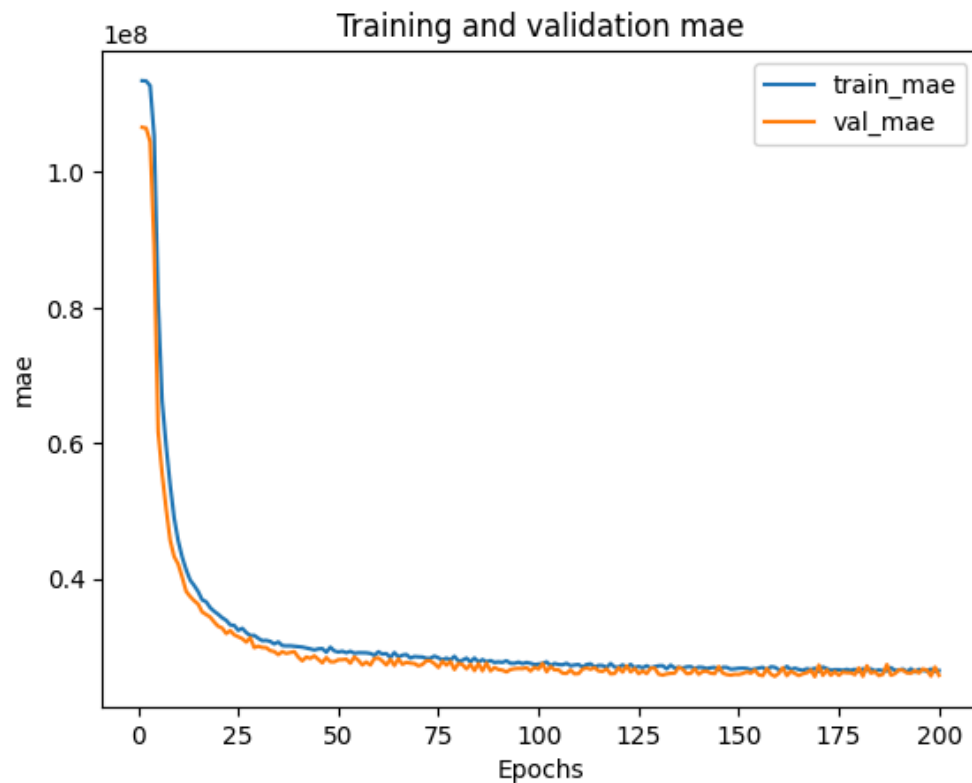
- Capa 1: 64 neuronas, activación ReLU
- Capa 2: 128 neuronas, activación ReLU
- Capa 3: 128 neuronas, activación ReLU
- Capa 4: 64 neuronas, activación ReLU
- Capa 5: 64 neuronas, activación ReLU
- Capa 6: 1 neurona, activación lineal


#### Resultados:

- Pérdida (loss):  $4.03e15$
- Error Absoluto Medio (MAE): 30,352,604

```
28/28 - 0s - 3ms/step - loss: 4031686337626112.0000 - mae: 30352604.0000
```

```
Model Unbatched - MAE: 30352604.0
```





## Red 2: Modelo Con Batch Normalization (Batched Model)

### Composición:



- Capa 1: 64 neuronas, activación ReLU, Batch Normalization
- Capa 2: 128 neuronas, activación ReLU, Batch Normalization
- Capa 3: 128 neuronas, activación ReLU, Batch Normalization
- Capa 4: 64 neuronas, activación ReLU, Batch Normalization
- Capa 5: 64 neuronas, activación ReLU, Batch Normalization
- Capa 6: 1 neurona, activación lineal

### Resultados:

- Pérdida (loss):  $6.53 \times 10^{15}$
- Error Absoluto Medio (MAE): 43,364,368

28/28 - 0s - 3ms/step - loss: 6532666195181568.0000 - mae: 43364368.0000

Model Batched - MAE: 43364368.0



### Red 3: Modelo Con Dropout (Dropout Model)

#### Composición:

- Capa 1: 64 neuronas, activación ReLU, Dropout 0.2
- Capa 2: 128 neuronas, activación ReLU, Dropout 0.2
- Capa 3: 128 neuronas, activación ReLU, Dropout 0.2
- Capa 4: 64 neuronas, activación ReLU, Dropout 0.2

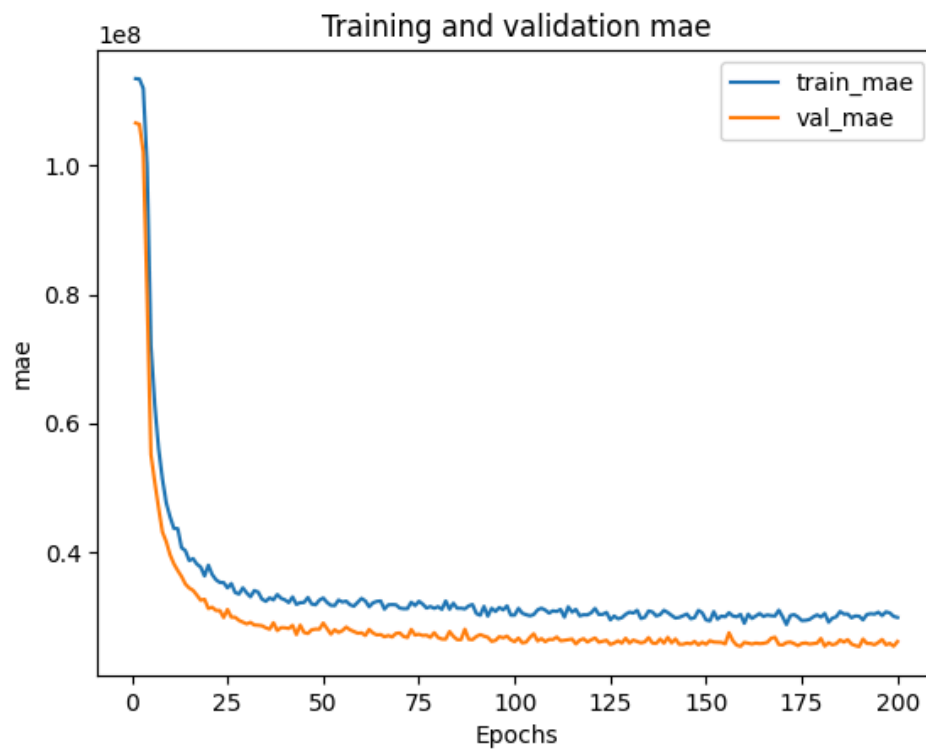
- Capa 5: 64 neuronas, activación ReLU, Dropout 0.2
- Capa 6: 1 neurona, activación lineal


### Resultados:

- Pérdida (loss):  $4.01e15$
- Error Absoluto Medio (MAE): 30,669,854

```
28/28 - 0s - 5ms/step - loss: 4009718922084352.0000 - mae: 30669854.0000
```

```
Model Dropout - MAE: 30669854.0
```





**3. Discuta la diferencia de rendimiento y conceptuales en la composición y resultados obtenidos en cada red neuronal.**

**Red 1: Modelo Sin Batch Normalization (Unbatched Model)**

En cuanto a rendimiento, este modelo muestra un MAE de 30,352,604, lo cual es significativamente más bajo que el modelo con Batch Normalization y es parecido al modelo con Dropout. La pérdida y MAE se estabilizan bastante rápido durante el proceso de entrenamiento, lo que nos demuestra una buena capacidad de aprendizaje.

Este modelo utiliza la función de activación ReLU, dándonos la capacidad para manejar el problema del gradiente desvaneciente. ReLU activa solo las neuronas con valores positivos, estableciendo los valores negativos a cero, lo que ayuda a la red a aprender patrones complejos sin saturar las activaciones. También, es importante resaltar que esta red no incorpora técnicas de regularización avanzadas como Batch Normalization o Dropout, lo que nos podría llevar a llevar a un menor riesgo de sobreajuste, pero también puede limitar la capacidad del modelo para generalizar a datos no vistos.

### **Red 2: Modelo Con Batch Normalization (Batched Model)**

El modelo de la red número 2 muestra un MAE de 43,364,368, lo cual es significativamente más alto que los otros dos modelos. Esto nos indica que la adición de Batch Normalization en cada capa puede no ser beneficiosa para este conjunto de datos específico y podría estar introduciendo una complejidad innecesaria para este tipo de datos.

En este modelo se normalizan las activaciones de la capa previa, acelerando el entrenamiento y proporcionando una mayor estabilidad al reducir el riesgo de desmotivaciones repentinas de neuronas. Sin embargo, la introducción de la normalización en cada capa podría haber llevado a una sobre-regularización que ha introducido demasiada variabilidad en las activaciones, dificultando el aprendizaje efectivo.

### **Red 3: Modelo Con Dropout (Dropout Model)**

En la red 3, se muestra un MAE de 30,669,854, lo cual es ligeramente superior al modelo sin Batch Normalization y bastante mejor que el modelo con Batch Normalization. La utilización de Dropout ayudó a reducir el sobreajuste y a mejorar la capacidad de generalización del modelo.

La inclusión de dropout desactiva aleatoriamente un porcentaje de neuronas durante el entrenamiento, obligando al modelo a aprender redundancias más robustas y prevenir el sobreajuste. Además, Dropout es una forma efectiva de regularización, especialmente en modelos profundos, ya que previene que el modelo dependa demasiado de neuronas específicas y fomenta la diversificación de los patrones aprendidos.

## **4. Seleccione la red neuronal óptima y justifique su respuesta.**

La red neuronal óptima seleccionada es la Red 1 (Unbatched Model) debido a su rendimiento comparable en términos de MAE con el modelo con Dropout, pero con la ventaja de simplicidad y eficiencia en el entrenamiento. Aunque ambos modelos muestran un rendimiento similar, la Red 1 es más sencilla, sin la necesidad de técnicas adicionales como Batch Normalization o Dropout, lo que nos ayuda y facilita el proceso de diseño, y también reduciendo la complejidad computacional. Esta simplicidad permite un entrenamiento más rápido y requiere menos recursos, mientras que no pierde o renuncia tanto en cuanto a sus predicciones precisas y generalización de datos no vistos. En conclusión, la Red 1 es más versátil y adecuada para predecir las ganancias totales de las películas, combinando precisión, eficiencia y facilidad de implementación.