



## **Laboratorio No. 3**

Carlos Edgardo López Barrera 21666

Brian Anthony Carrillo Monzon - 21108

Guatemala, 12 de agosto del 2024

# Capas

## Capas

### 1. Entrada:

- Tamaño de Entrada: Imágenes de 32x32 píxeles.

### 2. Primera Capa Convolucional:

- Número de Filtros: 32 filtros.
- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Padding: Same (mantiene la dimensión 32x32).
- Adicional: Batch Normalization.
- Propósito: Detectar características locales como bordes y texturas.

### 3. Segunda Capa Convolucional:

- Número de Filtros: 32 filtros.
- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Pooling: MaxPooling 2x2 (reduce la dimensión a 16x16).
- Adicional: Batch Normalization y Dropout (0.3).
- Propósito: Reducir la dimensionalidad y la sensibilidad a la ubicación de las características, evitando el sobreajuste.

### 4. Tercera Capa Convolucional:

- Número de Filtros: 64 filtros.
- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Padding: Same (mantiene la dimensión 16x16).
- Adicional: Batch Normalization.
- Propósito: Detectar patrones más complejos con mayor capacidad de filtro

### 5. Cuarta Capa Convolucional:

- Número de Filtros: 64 filtros.
- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Pooling: MaxPooling 2x2 (reduce la dimensión a 8x8).
- Adicional: Batch Normalization y Dropout (0.4).
- Propósito: Continuar la reducción de dimensionalidad y aumentar la robustez del modelo.

### 6. Quinta Capa Convolucional:

- Número de Filtros: 128 filtros.
- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Padding: Same (mantiene la dimensión 8x8).
- Adicional: Batch Normalization.
- Propósito: Extraer características aún más complejas.

### 7. Sexta Capa Convolucional:

- Número de Filtros: 128 filtros.

- Tamaño del Filtro: 3x3.
- Función de Activación: ReLU.
- Pooling: MaxPooling 2x2 (reduce la dimensión a 4x4).
- Adicional: Batch Normalization y Dropout (0.5).
- Propósito: Capturar la esencia final de las características detectadas.

Capas Densas:

#### 8. Primera Capa Densa:

- Número de Neuronas: 512 neuronas.
- Función de Activación: ReLU.
- Regularización: L2(0.01).
- Adicional: Batch Normalization y Dropout (0.5).
- Propósito: Combinar características extraídas y reducir la dimensionalidad para la siguiente capa.

#### 9. Segunda Capa Densa:


- Número de Neuronas: 84 neuronas.
- Función de Activación: ReLU.
- Regularización: L2(0.01).
- Adicional: Batch Normalization y Dropout (0.5).
- Propósito: Actuar como una capa de procesamiento final antes de la capa de salida.

#### 10. Capa de Salida:

- Número de Neuronas: 10 neuronas (correspondientes a las 10 clases de señales en el conjunto).
- Función de Activación: Softmax.
- Propósito: Producir probabilidades para cada clase y determinar la clase final para la predicción.

## Discusión

Métrica	Valor
Accuracy	0.80
Precision	0.81
Recall	0.80
F1-score	0.80



El valor de **accuracy** refleja que el modelo tiene una tasa de aciertos del 80.45% al clasificar las imágenes en las 10 categorías de animales. En otras palabras, de todas las imágenes procesadas, el 80.45% fueron clasificadas de manera correcta. La **precisión** se refiere a cuán exactas son las predicciones positivas del modelo; es decir, de todas las imágenes que el modelo identificó como pertenecientes a una categoría específica, el 80.97% realmente pertenecían a esa categoría. Por otro lado, el **recall** mide la habilidad del modelo para identificar todos los casos positivos en los datos; en este caso, el 80.45% de las imágenes que realmente pertenecían a una categoría específica fueron correctamente identificadas por el modelo. El **F1 Score**, que es la media armónica entre precisión y recall, tiene un valor de 0.8004, lo que sugiere un buen equilibrio entre estas dos métricas. Esto es crucial para un modelo de clasificación de imágenes, ya que garantiza que tanto la exactitud como la exhaustividad sean razonablemente elevadas.

Considerando que el conjunto de entrenamiento está compuesto por 50,000 imágenes, esta cantidad podría ser un factor contribuyente al error del modelo. Además, si las imágenes de entrenamiento no abarcan una amplia variedad de condiciones, como diferentes iluminaciones, ángulos, posturas o entornos, el modelo podría no generalizar correctamente a nuevas imágenes bajo diferentes circunstancias. Otra posible causa del error es el número de épocas de entrenamiento: si el modelo no ha sido entrenado durante un número suficiente de épocas, puede que no haya aprendido adecuadamente las características esenciales, resultando en un desempeño inconsistente. Por último, la baja calidad de las imágenes y la ausencia de características distintivas podrían dificultar que el modelo extraiga las características correctas, lo que afectaría la consistencia de las predicciones.