



Laboratorio No. 4

Carlos Edgardo López Barrera 21666

Brian Anthony Carrillo Monzon - 21108

Guatemala, 19 de agosto del 2024


Feed Forward Neural Network (FNN)

Arquitectura del Modelo:

- Capa de Entrada (Input Layer):
 - Dimensión de Entrada: time_step
 - Tipo de Capa: Densa (Dense).
 - Número de Neuronas: 128.
 - Función de Activación: ReLU (Rectified Linear Unit)
- Primera Capa Oculta (First Hidden Layer):
 - Número de Neuronas: 64.
 - Función de Activación: ReLU.
- Segunda Capa Oculta (Second Hidden Layer):
 - Número de Neuronas: 32.
 - Función de Activación: ReLU.
- Tercera Capa Oculta (Third Hidden Layer):
 - Número de Neuronas: 16.
 - Función de Activación: ReLU.
- Capa de Salida (Output Layer):
 - Número de Neuronas: 1 1 (regresión).
 - Función de Activación: Lineal (linear).

Entrenamiento del Modelo:

- Número de Epochs: 100
- Tamaño de Batch: 32




Recurrent Neural Network (RNN)

Arquitectura del Modelo:


- Primera Capa LSTM (First LSTM Layer):
 - Número de Unidades: 100
 - Return Sequences: True
 - Input Shape: (time_step, 1)
- Segunda Capa LSTM (Second LSTM Layer):
 - Número de Unidades: 50
 - Return Sequences: False
 - Capa Densa (Dense Layer):
 - Número de Neuronas: 25.
 - Función de Activación: ReLU.
- Capa de Salida (Output Layer):
 - Número de Neuronas: 1 (regresión).
 - Función de Activación: Lineal (linear)

Entrenamiento del Modelo:

- Número de Epochs: 100
- Tamaño de Batch: 32



Discusión



Feed Forward Neural Network (FNN)

- Pros:
 - Simplicidad: La FNN es más fácil de implementar, especialmente cuando se trabaja con datos que no tienen una naturaleza secuencial fuerte.
 - Tiempo de Entrenamiento: Las FNN generalmente se entrena más rápido en comparación con las RNN
 - Buen Rendimiento en Datos No Secuenciales: Las FNN suelen predecir bien cuando las dependencias temporales no son tan importantes.
- Contras:
 - Dependencias Temporales: Las FNN no son adecuadas para datos secuenciales o dependencias temporales.
 - Sobreajuste: Aunque la FNN puede aprender rápidamente, es posible que no generalice tan bien en datos de series temporales.

Recurrent Neural Network (RNN) Mejorada

- Pros:
 - Dependencias Temporales: Las RNN, especialmente con capas LSTM, son capaces de capturar dependencias a largo plazo en los datos.
 - Rendimiento en Series Temporales: Como se ve en los resultados, la RNN mejorada ofrece un MSE más bajo que la FNN, lo que indica que está mejor adaptada para manejar la naturaleza secuencial de los datos.
 - Flexibilidad: Las RNN pueden manejar secuencias de longitud variable
 -

- Contrás:
 - Complejidad: Las RNN son más difíciles de implementar, y requieren más recursos computacionales debido a su estructura más compleja.
 - Sobreajuste: Aunque las RNN capturan mejor las relaciones temporales, también son propensas a sobreajustar, especialmente con conjuntos de datos pequeños.
 - Tiempo de Entrenamiento: Las RNN generalmente requieren más tiempo.

Justificación Basada en los Resultados Obtenidos

- Feed Forward Neural Network (FNN):

El MSE obtenido para la FNN fue de 0.005098, lo cual indica que el modelo logró un buen desempeño, pero su capacidad para generalizar en series temporales es limitada en comparación con la RNN.
- Recurrent Neural Network (RNN) Mejorada:

El MSE de la RNN mejorada fue de 0.004449, lo que representa un mejor ajuste y capacidad predictiva en comparación con la FNN. Esto se debe a la habilidad de la RNN para capturar relaciones temporales en los datos.

Elección Final

Tomando en cuenta la naturaleza secuencial del dataset, donde es fundamental capturar las dependencias temporales para hacer predicciones precisas, la RNN sería la mejor opción para resolver este problema de regresión. Aunque es más compleja y requiere más tiempo de entrenamiento, maximiza la precisión y generalización en series temporales.